



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
LICENCIATURA EN CIENCIA DE DATOS



Unidad de Aprendizaje:

Analítica Avanzada de Datos

Profesora:

Sánchez Manilla Ángeles Alejandra

PROYECTO FINAL

Hospital

6AM2

PRESENTAN:

Huerta Rodríguez Sofía

Melgarejo Zarate Karla Gabriela

Zhang Tan Rubi

Ciudad de México, a 26 de junio de 2026.

ÍNDICE

Planteamiento del Problema	1
Objetivo	1
Dataset.....	1
Variables	1
Variable Objetivo y Desbalance de Clases	3
Preprocesamiento y Tratamiento de Nulos	4
Ingeniería de Variables	5
Manejo de códigos CIE-9.....	5
Ingeniería de medicamentos.....	6
Tratamiento de Outliers y Multicolinealidad	8
Winsorización	8
Control de multicolinealidad (VIF)	9
Pipeline y Validación Cruzada.....	9
Modelado.....	10
Modelo 1: Regresión Logística con Elastic Net.....	10
Modelo 2: XGBoost (Ensamble de Gradient Boosting)	11
Modelo 3: Random Forest (Bagging)	11
Modelo 4: LightGBM (Gradient Boosting)	11
Evaluación bajo desbalance	11
Comparación de modelos.....	12
Ajuste del umbral de decisión	13
Evaluación final sobre el conjunto de prueba.....	14
Interpretación de Coeficientes (Odds Ratios).....	14
Variables con Target Encoding	16
Intervalos de confianza	16
Explicabilidad (SHAP)	16
Explicabilidad global de modelos de árbol	17
Explicabilidad global del modelo lineal.....	17
Explicabilidad local.....	18
Análisis de Sesgo Algorítmico (Fairness).....	18
Comparación de recall por raza	19

Fairness del modelo ganador por grupo de edad y por grupo de raza.....	19
Conclusiones.....	21

ÍNDICE DE FIGURAS

Figura 1. Distribución de la variable readmitted y de la variable objetivo-binaria.	4
Figura 2. Porcentaje de valores nulos por columna.....	4
Figura 3. Distribución de macro-categorías para diag_1, diag_2 y diag_3 tras el mapeo CIE-9.	6
Figura 4. Distribución de medicamentos activos, cambios de dosis y prevalencia de polifarmacia.	7
Figura 5. Distribución de las variables de frecuencia de uso del sistema de salud antes de la Winsorización.....	8
Figura 6. Variables después de la Winsorización.	8
Figura 7. VIF de las variables numéricas candidatas.	9
Figura 8. Curvas Precision-Recall y comparación de métricas.....	12
Figura 9. Búsqueda del umbral óptimo según F2-Score.....	13
Figura 10. Matrices de confusión sobre el conjunto de prueba.....	14
Figura 11. Odds Ratio de las variables	15
Figura 12. SHAP global de modelos de árbol.....	17
Figura 13. SHAP global del modelo lineal	17
Figura 14. Recall por grupo de raza.....	19
Figura 15. Fairness del modelo ganador por grupo de edad y grupo de raza	20

Planteamiento del Problema

El presente proyecto aborda un desafío clínico costoso en el sistema hospitalario, el reingreso no planeado de pacientes diabéticos dentro de los 30 días siguientes al alta. Lo anterior puede conllevar consecuencias graves clínicas, por ejemplo, el deterioro del estado del paciente como condiciones que se pueden evitar o bien, económicas, como el costo promedio de un reingreso prematuro en Estados Unidos ya que supera los \$15,000 dólares por episodio, además de que programas como Medicare/Medicaid suelen penalizar económicamente a hospitales con tasas de reingresos elevadas.

Objetivo

El objetivo del proyecto es desarrollar un sistema predictivo end-to-end para identificar si un paciente diabético corre el riesgo de ser readmitido en el hospital en un plazo menor a 30 días tras su alta.

Dataset

Se utilizó el dataset Diabetes 130-US Hospitals for Years 1999-2008, agrupa 101,766 encuentros hospitalarios registrados en 130 hospitales de Estados Unidos. Cada fila del dataset representa un encuentro, cabe aclarar que no es un paciente único, esto con información acerca de datos demográficos del paciente, diagnósticos primarios y secundarios en códigos CIE-9, también procedimientos, medicamentos y resultados de laboratorio.

Variables

Identificadores

Encounter ID	Identificador único de cada visita hospitalaria
Patient number	Identificador único del paciente. Un mismo paciente puede tener varias IDs.

Demográficas

Race	Raza del paciente	Caucasian, Asian, African American, Hispanic, Other, nulos.
Gender	Sexo del paciente	Male, female, unknown/invalid.
Age	Edad	Agrupada en intervalos de 10 años
Weight	Peso	Peso en libras

Encuentro hospitalario

Admission type	Tipo de admisión	9 valores: emergencia, urgente, electiva, recién nacido, etc
Discharge disposition	Destino al alta	29 valores: casa, otro hospital, fallecido, hospicio
Admission source	Fuente de admisión	21 valores: referido por médico, sala de emergencia, transferencia, etc
Time in hospital	Días de estancia	Entre 1 y 14

Administrativas

Payer code	Código del asegurado	23 valores: Blue Cross/Blue Shield, Medicare, Medicaid, etc. 52% nulos
Medical specialty	Especialidad del médico tratante	84 valores: cardiología, medicina interna, cirugía, etc. 53% nulos

Variables clínicas de procedimientos y medicamentos

Number of lab procedures	Cantidad de pruebas de laboratorio realizadas en el encuentro
Number of procedures	Cantidad de procedimientos clínicos distintos de laboratorio
Number of medications	Cantidad de medicamentos genéricos distintos administrados
Number of outpatient visits	Visitas ambulatorias del paciente en el año previo al encuentro
Number of emergency visits	Visitas a urgencias en el año previo
Number of inpatient visits	Hospitalizaciones previas en el año anterior
Number of diagnoses	Total de diagnósticos ingresados al sistema durante el encuentro

Diagnósticos

Diagnosis 1	Diagnóstico primario	848 valores distintos
Diagnosis 2	Diagnóstico secundario	923 valores distintos
Diagnosis 3	Diagnóstico secundario adicional	954 valores, 1% nulos

Resultados de laboratorio

Glucose serum test result	Resultado de la prueba de glucosa en suero	>200, >300, Normal, None
A1c test result	Resultado de HbA1c	>8 mal control, >7 control regular, Normal >7%, None

Variables de medicación general

Change of medications	Si hubo algun cambio en medicamentos durante el encuentro	Change, no change
Diabetes medications	Si se prescribió algún medicamento antidiabético	Yes, no

24 variables de medicamentos específicos.

Hay una columna por cada fármaco antidiabético, los cuales son: metformin, repaglinide, nateglinide, chlorpropamide, glimepiride, acetohexamide, glipizide, glyburide, tolbutamide, pioglitazone, rosiglitazone, acarbose, miglitol, troglitazone, tolazamide, examide, citoglipton, **insulin**, glyburide-metformin, glipizide-metformin, glimepiride-pioglitazone, metformin-rosiglitazone, metformin-pioglitazone.

Cada una toma los valores:

- Up (dosis aumentada)
- Down (dosis reducida)
- Steady (dosis sin cambio)
- No (no prescrito)

Variable Objetivo y Desbalance de Clases

La variable objetivo es readmitted, originalmente tiene tres niveles, que son:

- <30: readmitido antes de 30 días
- >30: readmitido después de 30 días
- NO: sin readmisión

El objetivo del proyecto es específicamente el riesgo de ingreso prematuro, así que se decidió convertir el problema en binario, teniendo los siguientes dos niveles:

- 1 = <30
- 0 = cualquier otro caso (>30 o NO)




Figura 1. Distribución de la variable *readmitted* y de la variable *objetivo-binaria*.

Observando las gráficas de distribución, la clase positiva de reingreso <30 días, representa el 11.16% de los 101,766 encuentros, lo que evidencia un desbalance de clases. Este desbalance tiene dos impactos importantes en el proyecto, los cuales son:

- Accuracy se descarta como métrica de evaluación por que puede arrojar resultados engañosos por el desbalance al predecir la clase mayoritaria. También se optimizará PR-AUC/F-beta en lugar de accuracy o incluso ROC-AUC simple.
- Usaremos StratifiedKFold en la validación cruzada para que cada fold conserve la misma proporción de las clases.

Preprocesamiento y Tratamiento de Nulos

El dataset presenta valores faltantes en varias columnas que están codificados como "?".




Figura 2. Porcentaje de valores nulos por columna.

En la siguiente tabla se presenta la estrategia aplicada para cada variable con valores nulos, ya que no se realizó ninguna eliminación de filas o columnas.

Variables	% nulos	Estrategia
weight	96.85%	Categoría "Missing"
max_glu_serum, A1Cresult	94.81%, 83.05%	Moda por grupo (age, gender)
medical_specialty	48.94%	Categoría "Missing"
payer_code	39.66%	Categoría "Missing"
Race	2.25%	Categoría "Missing"
diag1, diag_2, diag_3	0.02%, 1.43%	Categoría "Missing"

Justificación de las estrategias aplicadas

- Para las variables weight, max_glu_serum, A1Cresult, existen nulos masivos, pero, aquí se identificó que no son errores de captura, sino que los nulos reflejan que esas mediciones no fueron solicitadas para la mayor parte de los encuentros, por lo que se decidió que es información clínica real y no ruido.
- Para las variables medical_specialty y payer_code, existen nulos más moderados que los pasados, también posiblemente informativos, ya que la ausencia de un especialista asignado o de un código de aseguradora podría estar correlacionado con el tipo de atención recibida.
- Para las variables race, diag_1/2/3, hay nulos mucho más moderados que los dos puntos anteriores así que se trató con el resto de las categorías.

El resultado de las estrategias de tratamiento de nulos arrojó un dataset libre de valores nulos.

Ingeniería de Variables

Manejo de códigos CIE-9

Las variables diag_1, diag_2 y diag_3, contienen muchos códigos médicos diferentes, esto es bastante para un One-Hot directo y es arriesgado para el Target Encoding considerando no agrupar las categorías.

Por lo anterior, se decidió aplicar un mapeo basado en los rangos numéricos estándar de la clasificación CIE-9, esto agrupa los códigos en macro categorías clínicas bastante usadas en la literatura del dataset, las cuales fueron:

- Circulatorio
- Diabetes
- Respiratorio

- Digestivo
- Lesiones/Envenenamiento
- Musculoesquelético
- Genitourinario
- Neoplasias
- "Otros" (incluyendo los códigos que inician con V o E, que en CIE-9 corresponden a factores externos y de salud suplementarios, no a enfermedades en sí).

Sobre esas macro categorías reducidas, es donde se aplica el Target Encoding.




Figura 3. Distribución de macro-categorías para diag_1, diag_2 y diag_3 tras el mapeo CIE-9.

Se puede observar que la agrupación redujo la cardinalidad ya que se pasó de 716-789 códigos a solo 9-11 macro categorías por columna de diagnóstico y sin perder la semántica clínica importante.

También se ve que “Circulatorio” y “Diabetes” dominan como diagnóstico primario lo que es coherente con el dataset ya que sabemos que está filtrado a pacientes diabéticos.

Ingeniería de medicamentos

El dataset cuenta con 23 columnas de medicamentos como insulina, metformina, etc, y cada uno con 4 valores posibles los cuales son:

- No = no prescrito
- Steady = dosis sin cambio
- Up = dosis aumentada
- Down = dosis reducida

Para no dejar la información así de dispersa en 23 variables categóricas, se decidió diseñar variables sintéticas que resumen el comportamiento del tratamiento, siendo los siguientes:

- **n_medicamentos_activos:** cuántos de los medicamentos están prescritos como $j = \text{"No"}$, sin importar si la dosis fue cambiada, esto mide amplitud del régimen farmacológico
- **treatment_complexity:** cuántos medicamentos tuvieron un cambio de dosis, como up o down durante el encuentro, esto mide que tan inestable o ajustado fue el tratamiento
- **polypharmacy_index:** definido clínicamente como tener 5 o más medicamentos activos simultáneamente, esto para identificar pacientes en riesgo de interacciones medicamentosas y eventos distintos
- **insulin_change:** es un indicador binario acerca de si específicamente la insulina cambio de dosis, ya que la insulina es el medicamento más prescrito y relevante clínicamente en el control glucémico de un paciente diabético hospitalizado.




Figura 4. Distribución de medicamentos activos, cambios de dosis y prevalencia de polifarmacia.

Encuentros con polifarmacia (≥ 5 medicamentos activos): 63 (0.06%)

Encuentros con cambio de insulina: 22,895 (23.05%)

Se puede observar que la mayoría de los encuentros tiene 1 o 2 medicamentos activos y entre 0 y 1 cambio de dosis, con una cola hacia regímenes más complejos.

El umbral de polifarmacia identifica que hay un subgrupo minoritario pero importante, estos pacientes están concentrados en mayor riesgo de interacciones medicamentosas y por ende, potencialmente mayor riesgo de reingreso por la dificultad que tienen de manejar regímenes completos tras el alta.

Respecto al cambio de la insulina, ocurre en una fracción no trivial de encuentros, lo que refleja que el ajuste de la insulina durante la hospitalización es una práctica clínica frecuente durante el manejo agudo de la diabetes.

Tratamiento de Outliers y Multicolinealidad

Winsorización

Las variables `number_inpatient` y `number_emergency` son variables de conteo con colas muy largas, ya que unos pacientes crónicos extremos pueden tener bastantes visitas previas, mientras que la mayoría tiene 0 o 1. Si no se tratan estas variables, los valores extremos podrían distorsionar los coeficientes y residuos del modelo lineal. Por esta razón se decidió aplicar winsorización al percentil 99, que lo que hace es recortar los valores extremos al límite superior conservando la fila completa.

Antes:




Figura 5. Distribución de las variables de frecuencia de uso del sistema de salud antes de la Winsorización.

Después:




Figura 6. Variables después de la Winsorización.

`number_inpatient`: 704 valores recortados al percentil 99 (límite = 6.0)

`number_emergency`: 930 valores recortados al percentil 99 (límite = 3.0)

`number_outpatient`: 903 valores recortados al percentil 99 (límite = 5.0)

Observando los boxplots, el recorte afecta únicamente al 1% superior de cada variable.

Control de multicolinealidad (VIF)

Para el control de la multicolinealidad se hizo el cálculo del VIF sobre las variables numéricas candidatas para descartar multicolinealidad severa antes de hacer la interpretación de coeficientes del modelo lineal.




Figura 7. VIF de las variables numéricas candidatas.

Un VIF por encima de 5 nos dice que hay colinealidad preocupante, y por encima de 10 es motivo de exclusión o regularización. En la gráfica podemos observar que las variables clínicas como num_medications, num_lab_procedures, time_in_hospital, muestran VIFs bajos. Variables como treatment_complexity e insulin_change, tienen VIFs de un valor alrededor del 4 pero sin superar o alcanzar el 5, se sabe que ambas se derivan de la misma fuente de información. Por lo anterior, no se elimina ninguna variable ya que ninguna alcanza el umbral crítico de 5.

Pipeline y Validación Cruzada

Se definieron tres grupos de columnas, cada uno con propio tratamiento dentro de ColumnTransformer, de esta manera, todas las etapas del preprocesamiento quedan integradas dentro del pipeline y se ejecutan nuevamente en cada partición de datos de la validación cruzada. Con esto, se evitó que información del conjunto de prueba influyera en el entrenamiento previniendo problemas de data leakage.

- Variables numéricas: se utilizó RobustScaler, este se basa en la mediana y el rango intercuartílico, es sensible a valores atípicos y no requiere que los datos sigan una distribución normal
- Variables categóricas con pocas o moderadas categorías: se aplicó One-Hot Encoding para convertir cada categoría en variables binarias
- Variables categóricas con muchas categorías: se empleó Target Encoding calculado solo con los datos de entrenamiento de cada fold e integrado directamente en el pipeline mediante category_encoders.

El conjunto de datos se dividió en 80% para entrenamiento y 20% para prueba, la división se realizó usando estratificación sobre la variable objetivo para conservar en ambos conjuntos la misma distribución de clases.

Modelado

Se llevó a cabo la implementación de dos tipos de modelos, primero un modelo lineal regularizado que fue Regresión Logística con penalización Elastic Net y después modelos de ensamble que fueron XGBoost, Random Forest y LightGBM.

Modelo 1: Regresión Logística con Elastic Net

La penalización con Elastic Net que es la combinación de L1 y L2 con l1_ratio=0.5, fue seleccionada por dos aspectos importantes:

- a) L1 realiza selección de variables, llevando a cero los coeficientes redundantes, en especial los de One-Hot de medical_speciality y payer_code, que generan alta dimensionalidad.
- b) L2 estabiliza los coeficientes ante la colinealidad moderada.

El hiperparámetro de regularización fue fijado en $C = 1.0$, con solver SAGA, necesario para Elastic Net en scikit-learn y max_iter = 2,000 para poder asegurar la convergencia en alta dimensionalidad.

El uso de class_weight="balanced" hizo que scikit-learn ponderara internamente cada muestra positiva 8 veces más que una negativa durante el ajuste, lo que compensa el desbalance si necesidad de un submuestreo explícito. La validación se realizó con cross_val_predict(method='predict_proba', generando probabilidades out-of-fold que no ven su propia información durante el entrenamiento del encoder.

Modelo 2: XGBoost (Ensamble de Gradient Boosting)

XGBoost fue elegido modelo de ensamble por la capacidad que tiene de capturar interacciones no lineales y también relaciones complejas entre variables, algo que la regresión logística no puede modelar directamente. Los hiperparámetros fueron:

- `n_estimators = 300` árboles, `learning_rate = 0.05`: para aprendizaje gradual y evitar sobreajuste
- `max_depth = 5`. Para una profundidad moderada y equilibrio entre complejidad y generalización
- `subsample = 0.8` y `colsample_bytree = 0.8`
- `scale_pos_weight = 7.95`
- `eval_metric = 'aucpr'`

Modelo 3: Random Forest (Bagging)

Random Forest construye paralelamente árboles independientes sobre muestras bootstrap y promedia sus predicciones. Los hiperparámetros usados fueron:

- `n_estimators = 300` árboles
- `max_depth = 10`
- `min_samples_leaf=20`
- `class_weight="balanced"`

Modelo 4: LightGBM (Gradient Boosting)

Al igual que XGBoost, LightGBM es un algoritmo de boosting, pero crece los árboles por hoja en lugar de por nivel, lo que lo hace más rápido y preciso en datasets donde hay muchas variables categóricas de alta cardinalidad. Sus hiperparámetros fueron:

- `n_estimators = 300` árboles
- `max_depth = 5`
- `learning_rate=0.05`
- `subsample=0.8`
- `colsample_bytree=0.8`
- `is_unbalance=True`. Para la compensación de clases

Evaluación bajo desbalance

Como sabemos, existe un desbalance severo con aproximadamente 11% positivos de los registros que corresponden a pacientes con reingreso prematuro. Con ese contexto, métricas como Accuracy o incluso ROC-AUC pueden generar una respuesta con percepción bastante optimista para el desempeño de los modelos, ya que una buena clasificación de la clase mayoritaria puede ocultar deficiencias en la detección de los casos positivos. Las principales métricas utilizadas fueron:

Métrica	Justificación
PR-AUC (Área Bajo la Curva Precision-Recall)	Permite evaluar de una manera más adecuada la capacidad del modelo para identificar la clase minoritaria
F-beta Score ($\beta=2$)	Este otorga mayor importancia al recall que a la precisión, por lo que prioriza la detección de pacientes con riesgo de reingreso

Comparación de modelos

Modelo	PR-AUC (CV)	ROC-AUC (CV)
Regresión Logística con Elastic Net	0.1975	0.6421
XGBoost	0.2012	0.6468
Random Forest	0.1953	0.6472
LightGBM	0.2006	0.6458




Figura 8. Curvas Precision-Recall y comparación de métricas

Se puede observar en las curvas de Precision-Recall que están muy por encima de la línea base cercana al 11%, lo que representa que los dos modelos capturan señal real, es decir, los dos modelos si son capaces de identificar los patrones útiles que hay en los datos y realizar predicciones con valor práctico.

Haciendo la comparación de las métricas como PR-AUC y ROC-AUC entre todos los modelos, se puede evaluar cual aprovecha mejor la información disponible. XGBoost y LightGBM quedaron muy cerca entre sí porque ambos son gradient boosting y quedan por encima del Random Forest. Elastic Net queda debajo de los modelos de ensamble en PR-AUC, pero sigue siendo útil para la interpretabilidad

(Odds Ratio). XGBoost tiene mejores resultados ya que como se mencionó anteriormente, es capaz de modelar relaciones complejas e interacciones entre variables.

Ajuste del umbral de decisión

Se realizó un análisis de diferentes umbrales de clasificación utilizando las probabilidades generadas por el modelo XGBoost, ya que el valor de corte predeterminado de 0.5 no es necesariamente la mejor alternativa cuando hay un desbalance de clases.

Para realizar la selección del umbral óptimo se calculó el F-beta Score $\beta=2$ sobre diferentes valores posibles, se eligió el que maximizó la métrica.




Figura 9. Búsqueda del umbral óptimo según F2-Score.

El mejor valor de F2-Score puede encontrarse en un umbral inferior a 0.5 ya que al existir pocos positivos, el modelo tiende a asignar probabilidades moderadas incluso a pacientes con riesgo elevado, entonces al reducir el umbral, se aumenta la cantidad de pacientes clasificados como alto riesgo, lo que mejora la capacidad de detección de reingresos reales.

Cabe mencionar que, aunque esta estrategia puede incrementar el número de falsas alarmas, también permite identificar una mayor proporción de pacientes que sí presentan reingreso, lo que se alinea con la prioridad clínica del problema.

Evaluación final sobre el conjunto de prueba

Una vez determinado el umbral óptimo, en donde solo se utilizó la información del entrenamiento y la validación cruzada, se volvió a entrenar el modelo XGBoost utilizando todo el conjunto de entrenamiento y se evaluó sobre el conjunto de prueba.




Figura 10. Matrices de confusión sobre el conjunto de prueba.

Umbral	F2-Score (CV)
0.50 por defecto	0.3774
0.38 óptimo	0.4126

Al observar la comparación de las dos matrices de confusión se puede decir que el ajuste del umbral redujo la cantidad de falsos negativos (pacientes que realmente presentan reingreso pero que no son detectados por el modelo), pero también se observa un incremento moderado en los falsos positivos.

Si esto se toma desde una perspectiva clínica, el intercambio es favorable, esto ya que una alerta adicional generalmente implica solo una acción preventiva o una llamada de seguimiento, mientras que un falso negativo puede representar la pérdida de una oportunidad para invertir oportunamente en un paciente con riesgo de reingreso. Por esto, el aumento del recall de la clase positiva obtenido tras el ajuste del umbral incluye un resultado que si es consistente con el objetivo del problema del proyecto.

Interpretación de Coeficientes (Odds Ratios)

La Regresión Logística permite la interpretación de sus coeficientes mediante los Odds Ratio (OR). Un OR mayor a 1 es mayor riesgo de reingreso y un OR menor a

1 es menor riesgo de reingreso. Como se implementó con Elastic Net, la penalización llevó a 26 coeficientes a cero, por lo que esas variables fueron descartadas, ya que el modelo las consideró redundantes o que no aportaban lo suficiente para ser consideradas.

En la siguiente tabla se muestran algunas variables y su Odds Ratio que obtuvieron.




Figura 11. Odds Ratio de las variables

Las variables que tuvieron el mayor OR fueron las de especialidades médicas. La variable que obtuvo el OR más alto es `medical_specialty_AllergyandImmunology` (Especialidad de Alergia/Inmunología), seguida de `medical_specialty_Psychiatry-Child/Adolescent` (Psiquiatría infantil) y `weight_[0-25)` (Peso muy bajo). Esto quiere decir que ciertos perfiles médicos en esas dos especialidades tienen mayor probabilidad de reingresar. Además, la variable más interpretable es `number_inpatient_wz`, ya que cada hospitalización anterior adicional, multiplica las odds de reingresar por 1.35.

Las variables con OR más bajo son especialidades también, como `medical_specialty_Gynecology` (Ginecología) y `medical_specialty_Pediatrics-Endocrinology` (Pediatria-Endocrinología), debido a que los pacientes pediátricos y ginecológicos tienen un perfil de egreso muy diferente a las personas diabéticas.

Variables con Target Encoding

El OR de las variables de diagnóstico (`diag_1_cat`, `diag_2_cat` y `diag_3_cat`) se interpreta como cuánto aumentan las probabilidades de reingreso por cada punto porcentual adicional en esa tasa histórica, ya que llegaron al modelo como un número continuo, a diferencia de las variables dummy.

En el `diag_1_cat` (1.0588), un punto porcentual más de la tasa histórica en el primer diagnóstico multiplica las probabilidades de reingreso por 1.0588.

Intervalos de confianza

Para los intervalos de confianza, se reestimó el modelo de Regresión Logística sin la regularización, sobre 31 variables numéricas y categóricas pobladas, y las 3 variables de Target Encoding.

Variable	OR	IC 95%	p-value	Significativo
<code>number_inpatient_wz</code>	1.34	[1.32, 1.36]	2.4e-270	Sí (muy alto)
<code>number_emergency_wz</code>	1.13	[1.08, 1.17]	4.1e-10	Sí
<code>insulin_change</code>	1.08	[0.97, 1.21]	0.156	No
<code>number_diagnoses</code>	1.08	[1.04, 1.13]	1.6e-04	Sí
<code>time_in_hospital</code>	1.08	[1.05, 1.12]	7.1e-06	Sí
<code>diag_1_cat</code>	1.07	[1.05, 1.09]	6.1e-11	Sí
<code>num_medications</code>	1.07	[1.03, 1.11]	2.8e-04	Sí
<code>diag_3_cat</code>	1.05	[1.03, 1.07]	6.1e-07	Sí
<code>diag_2_cat</code>	1.05	[1.02, 1.07]	2.7e-04	Sí
<code>race_Hispanic</code>	1.04	[0.89, 1.22]	0.623	No

La variable con el OR más alto e intervalo de confianza más grande es `number_inpatient_wz`, por lo que es el predictor más robusto de reingreso temprano con diferencia.

Explicabilidad (SHAP)

El análisis para los valores SHAP (SHapley Additive exPlanations) se hizo sobre una muestra de mil encuentros del conjunto de prueba.

Explicabilidad global de modelos de árbol

Para los 3 modelos de árbol, XGBoost, Random Forest y LightGBM, se usó TreeExplainer.




Figura 12. SHAP global de modelos de árbol

En las 3 gráficas se puede observar que `number_inpatient_ws` está en el primer lugar, tiene valores SHAP positivos y altos para los pacientes que tienen más hospitalizaciones anteriores. Que esta variable se encuentre en los 3 algoritmos quiere decir que, aunque los modelos tengan mecánicas diferentes (bagging vs boosting), coinciden en las mismas variables, por lo que hay más confianza de que no es un invento de un solo algoritmo, sino que es una señal real.

Explicabilidad global del modelo lineal

Para el modelo lineal se usó LinearExplainer, donde sus resultados coinciden con los Odds Ratio, `number_inpatient_ws` quedó en primer lugar, con `payer_code_Missing` en segundo lugar, seguido de variables de edad avanzada.




Figura 13. SHAP global del modelo lineal

A diferencia de los modelos de árbol, el SHAP de Elastic Net muestra que las variables `payer_code_Missing` y `diabetesMed_No` tienen mayor relevancia que lo que los modelos de árbol le asignan, debido a que el modelo lineal les da mas peso porque no puede capturar relaciones no lineales.

Explicabilidad local

De la muestra de mil encuentros, se seleccionó al paciente que tuvo la mayor probabilidad predicha por XGBoost. Su posición en la muestra fue el índice 221, con una probabilidad predicha de reingreso menor a 30 días de 86.4%, donde su etiqueta real en el set de prueba es Reingreso < 30 días, por lo que fue un positivo verdadero.

Las variables que más aumentaron el riesgo de este paciente fueron `numer_inpatient_ws`, `diag_1_cat`, `diag_2_cat`, y `medical_speciality_Hematology`. Es decir, el paciente tenía 5 hospitalizaciones previas, sus macro-categorías de diagnóstico tenían tasas históricas de reingreso de 15.9% y 15.8% respectivamente, que estuvieron por encima del promedio del dataset (11.2%). Además, fue atendido por Hematología, una de las especialidades con OR más alto.

Análisis de Sesgo Algorítmico (Fairness)

Para verificar que los modelos se comportan de manera equitativa para todos los grupos de edad y grupos de raza, se comparó su recall, es decir, qué proporción de los reingresos reales detectan los modelos en cada grupo.

Comparación de recall por raza




Figura 14. Recall por grupo de raza

El grupo con Missing en su raza tiene el recall más bajo en los 4 modelos, seguido de Other. Como esto es consistente en los 4 modelos, la causa puede ser porque hay menos registros de estos grupos para que los modelos aprendan sus patrones.

El modelo con el mejor recall en casi todos los grupos es XGBoost, pero también tiene la mayor brecha de 0.900 (Asian) contra 0.667 (Missing), por lo que un mayor poder predictivo agregado no asegura mayor equidad entre grupos de raza.

Fairness del modelo ganador por grupo de edad y por grupo de raza

Analizamos si el modelo ganador, XGBoost, se comporta de manera equitativa para los diferentes grupos de edad y raza.

Modelo: XGBoost




Figura 15. Fairness del modelo ganador por grupo de edad y grupo de raza

El rango de edad [0-10) no tiene ningún caso positivo real en el conjunto de prueba por la falta de registros contra los cuales medir. El rango de [10-20) tiene un recall de 0.30, el cual es el más bajo de los grupos con positivos reales debido a que hay muy pocos positivos para que el modelo pueda aprender sus patrones. Además, se puede observar que el recall crece con la edad, debido a que los pacientes mayores tienen historiales clínicos más largos.

Por otro lado, los grupos de Caucasian y AfricanAmerican son los que más registros tienen y obtuvieron un recall cercano al global. El grupo Asian tienen el recall y precisión más alta, ya que el modelo es más conservador en sus predicciones por sus 128 registros y una tasa base del 15.6%. El grupo Hispanic tiene un recall de 0.875 incluso teniendo una tasa base real baja, por lo que el modelo es relativamente bueno detectando los reingresos reales de esta raza. Por otro lado, Missing y Other tienen los recalls más bajos.

Conclusiones

El presente proyecto pudo construir un sistema predictivo de identificación de pacientes diabéticos con riesgo de reingreso al hospital en menos de 30 días. Se pudo observar que, de los cuatro modelos entrenados, el XGBoost fue el ganador. Este alcanzó un recall global de 0.840 en el conjunto de prueba con su umbral de decisión ajustado por F2-Score.

El hallazgo más importante y consistente del proyecto fue que el historial de hospitalizaciones previas es el predictor más fuerte, debido a que tiene un Odds Ratio de 1.342 con un intervalo de confianza al 95% de [1.32, 1.36] y un p-value de $2.4e-270$. Además, aparece en primer lugar en los cuatro modelos según su valor de SHAP. Los tres diagnósticos clínicos agrupados (diag_1_cat, diag_2_cat y diag_3_cat) fueron estadísticamente significativos después de hacer el Target Encoding, donde el diagnóstico primario fue el que mayor efecto tuvo. En cuanto al modelo lineal, descartó 26 variables de 165 por la penalización Elastic Net, por lo que fue útil para tratar la alta dimensionalidad generada por las especialidades médicas y los medicamentos.

El análisis de equidad de los modelos mostró que las razas con mayor representación (AfricanaAmerica, Caucasian, Hispanic) tuvieron recalls cercanos al global, por lo que los modelos no discriminan a estos grupos. No obstante, los grupos Missing y Other en la raza tienen recalls más bajos en los cuatro modelos porque no hay suficientes registros para que los modelos puedan aprender sus patrones de manera confiable. Esto sucede de manera similar con el grupo de edad [0-10), ya que con solo 146 registros y una tasa base de reingreso de 6.8%, obtuvo un recall de 0.30. En cambio, se identificó una tendencia: el recall crece con la edad. Los pacientes mayores tienen historiales clínicos más amplios, lo cual es lógico y es una señal que los modelos aprovechan.

El umbral de decisión se calculó maximizando el F2-Score, el cual da cuatro veces más peso a detectar reingresos reales que a evitar falsas alarmas. Sin embargo, este umbral debería revisarse por su equipo clínico por hospital para ajustarlo de acuerdo con el costo real de cada tipo de error en un contexto específico que se requiera analizar.